

Proyecto 1 - LSA con SVD

Reinaldo Oliva Morales Ignacio Osorio Orellana

IMT2230 - Álgebra Lineal Avanzada y Modelamiento

Pontificia Universidad Católica de Chile

15 de mayo de 2026

Resumen

Aplicamos *Latent Semantic Analysis* (LSA) mediante la descomposición en valores singulares (SVD) sobre una matriz término-documento TF-IDF construida a partir de 294 resúmenes de artículos de Wikipedia en español, organizados en cinco categorías temáticas (deporte, ciencia, economía, cultura, historia). La SVD recupera, sin supervisión, ejes interpretables que separan los temas; la similitud coseno en un espacio reducido a $k = 20$ entrega vecindades coherentes (clusters por categoría con similitud $\geq 0,85$). Tres de los cuatro puntos de la hipótesis inicial se confirman; el restante (concentración rápida de la energía en pocas componentes) se refuta, evidenciando que el corpus tiene rango efectivo alto.

1. Elección y descripción del corpus

Usamos **Wikipedia en español** como corpus. Cada documento es el *lead section* (resumen introductorio) de un artículo, equivalente a un abstract enciclopédico del tema. La fuente es abierta y reproducible: el código descarga los artículos vía la API pública `wikipedia-api` y guarda el resultado en `corpus_wikipedia.csv` para evitar redescargas.

Elegimos cinco categorías temáticas marcadamente distintas. Para cada una intentamos descargar 60 artículos; el total efectivo fue de **294 documentos** porque algunos títulos no existen exactamente con el nombre buscado o no superan el umbral mínimo de longitud:

Tabla 1: Distribución de documentos por categoría temática en el corpus.

Categoría	Descripción	Documentos
deporte	Deportes, competiciones, atletas	60
ciencia	Física, biología, astronomía, matemáticas	60
economia	Macroeconomía, finanzas, comercio	60
cultura	Cine, arte, literatura, música	59
historia	Eventos y personajes históricos	55
Total		294

El corpus es interesante porque las cinco áreas tienen vocabularios disjuntos (un artículo de física comparte casi nada con uno de fútbol), lo que constituye un buen banco de pruebas para verificar si la SVD descubre la separación temática sin etiquetas.

2. Hipótesis inicial

Antes de ejecutar el análisis formulamos cuatro predicciones concretas:

1. Los documentos de la misma categoría quedarán **agrupados en clusters** en el espacio reducido.
2. Los **términos característicos** de cada área aparecerán en regiones separadas del mapa 2D de términos.
3. Los **primeros 5–10 valores singulares** concentrarán una fracción importante de la energía total.
4. La categoría **historia** podría solaparse parcialmente con **economía/política**, ya que comparten vocabulario histórico-político (*gobierno, imperio, crisis, revolución*).

3. Preprocesamiento del texto

Pipeline aplicado a cada documento:

1. **Minúsculas.**
2. **Eliminación de caracteres no alfabéticos** (se conservan tildes y la ñ).
3. **Eliminación de stopwords** usando una **lista manual** en español (172 términos base: artículos, preposiciones, conjunciones, pronombres y formas verbales auxiliares), **ampliada con 75 stopwords “enciclopédicas”** propias de Wikipedia (*denominado, conocido, llamado, encuentra, trata, refiere, etc.*). Sin este segundo grupo, dichos términos dominan las primeras componentes de la SVD sin aportar significado temático.
4. **Filtro por longitud:** descartamos tokens de menos de 3 caracteres.

Tras la limpieza pasamos a TF-IDF con `TfidfVectorizer` de scikit-learn:

- `sublinear_tf=True` → $1 + \log(\text{tf})$ (comprime frecuencias altas).
- `min_df=3` (descarta hápax) y `max_df=0.80` (descarta términos hiperfrecuentes).
- `max_features=3000` → conserva los 3000 términos más informativos por TF-IDF global.
- `norm='l2'` → norma euclídea unitaria por documento.

Vocabulario final: 3000 términos. La entrada A_{ij} representa el peso TF-IDF del término i en el documento j .

4. Construcción de la matriz textual

Seguimos la convención del curso y construimos la matriz **término-documento**

$$A \in \mathbb{R}^{m \times n}, \quad m = 3000, \quad n = 294,$$

donde las **filas** son términos y las **columnas** son documentos. scikit-learn entrega la transpuesta (documentos $\times$ términos), por lo que aplicamos `X.T.toarray()`. La densidad de A es del **3.11 %** (27 434 entradas no nulas de 882 000 posibles), consistente con una matriz dispersa típica de TF-IDF.

El peso TF-IDF en cada entrada favores términos frecuentes en el documento pero raros en el corpus, exactamente lo que necesita la SVD para detectar estructura temática.

5. Cálculo de la SVD

Calculamos la descomposición $A = U\Sigma V^\top$ con `numpy.linalg.svd(A, full_matrices=False)` (SVD reducida):

- $U \in \mathbb{R}^{3000 \times 294}$: cada columna $U_{:,k}$ es una **dirección principal en el espacio de términos** (“concepto latente” k).
- $\Sigma \in \mathbb{R}^{294 \times 294}$: diagonal con $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$; σ_k mide la **importancia del concepto** k .
- $V^\top \in \mathbb{R}^{294 \times 294}$: la fila k indica cómo se proyectan los **documentos** sobre el concepto k .

Los primeros valores singulares obtenidos son:

$$\sigma_1 = 3,522, \quad \sigma_2 = 2,212, \quad \sigma_3 = 2,103, \quad \sigma_4 = 1,987, \quad \sigma_5 = 1,866, \dots, \sigma_{20} = 1,337.$$

Verificamos numéricamente que $\|A - U\Sigma V^\top\|_F \approx 6 \times 10^{-14}$ (esencialmente cero debido a la precisión de máquina).

6. Valores singulares y elección de k




Figura 1: Decaimiento de valores singulares y energía acumulada del espectro.

Lectura del decaimiento. Se observan dos rasgos clave:

1. **Caída brusca inicial:** $\sigma_1 \rightarrow \sigma_2$ pierde un 37 % de magnitud. Las primeras 5–6 componentes marcan un cambio de régimen claro en el decaimiento.
2. **Decaimiento lento posterior:** de σ_7 en adelante la curva es casi lineal, comportamiento clásico de corpus heterogéneos con múltiples temas distribuidos.

La **energía acumulada** crece a un ritmo paulatino: $k = 20$ captura solo el **21.2 %** de la varianza total, $k = 5$ captura el 9.9 %, y para alcanzar el 80 % del espectro se requieren $k = 183$ componentes (más de la mitad del rango total).

Elección de $k = 20$. Pese a la energía modesta, $k = 20$ es razonable porque para tareas exploratorias como clustering, búsqueda de vecinos cercanos y visualización *no* hace falta reconstruir A con error bajo — basta con que las direcciones retenidas separen los tópicos esenciales. Como veremos, las componentes 2–5 ya codifican la estructura semántica principal.

7. Representación de documentos y términos en baja dimensión

A partir de la SVD truncada construimos las coordenadas en dos dimensiones:

- **Documentos:** $D_2 = \Sigma_2 V_2^\top \in \mathbb{R}^{2 \times n}$.
- **Términos:** $T_2 = U_2 \Sigma_2 \in \mathbb{R}^{m \times 2}$.

7.1. Documentos en (C1, C2)




Figura 2: Proyección de los documentos en el plano determinado por las componentes 1 y 2.

Todos los puntos quedan confinados en el semiplano $x < 0$: la **componente 1 no separa por tema** sino que captura una dirección de “magnitud” general del documento (vector TF-IDF promedio). La componente 2 sí implementa una separación temática: arriba quedan los documentos de ciencia (azul) y economía (rojo); abajo, historia (morado) y deporte (verde). **Historia** es la categoría más nítidamente segregada; cultura ocupa la franja central debido a su heterogeneidad interna inherente.

7.2. Documentos en (C2, C3) — Visualización temática real




Figura 3: Proyección temática efectiva de los documentos usando las componentes 2 y 3.

Al descartar la C1 (genérica) y graficar las dos primeras direcciones verdaderamente semánticas, los **cinco clusters se vuelven claramente distinguibles**:

- **Deporte** se separa hacia la zona superior-izquierda (C2 negativa, C3 positiva).
- **Ciencia** ocupa predominantemente la zona derecha (C2 positiva).
- **Historia** queda concentrada en la esquina inferior-izquierda.
- **Economía** aparece compacta en la zona inferior-derecha.
- **Cultura** forma una banda intermedia que sirve de puente entre áreas, coherente con su dispersión.

7.3. Términos relevantes en (C1, C2)

Seleccionamos los términos con valores más extremos en cada eje. El eje C2 muestra una contraposición temática nítida: arriba palabras como **teoría**, **estudia**, **materia**, **energía**, **física**,




Figura 4: Visualización espacial de términos relevantes en los ejes de componentes 1 y 2.

ciencia; abajo términos como guerra, imperio, españa, francia, militar, política. El eje C1 muestra vocabulario transversal de alta frecuencia (siglo, años, estados, mundial) en el extremo negativo, confirmando que C1 es un eje de escala, no de contraste temático.

8. Exploración semántica

8.1. Ejemplo 1: ¿qué tema captura cada componente?

Los polos (+) y (−) de cada vector singular izquierdo $U_{:,k}$ revelan el concepto latente que captura esa componente particular:

Tabla 2: Interpretación conceptual de las primeras 5 componentes singulares.

Comp.	Polo (+)	Polo (−)	Interpretación Semántica
1	Términos raros/específicos	siglo, años, estados, mundial	Magnitud y generalidad
2	teoría, estudia, materia, energía	guerra, imperio, francia, militar	Ciencia ↔ Historia / Política
3	deporte, juegos, olímpicos, equipo	política, economía, gobierno	Deporte ↔ Política / Economía
4	música, arte, cine, literatura	bienes, mercado, monetaria	Cultura ↔ Economía
5	materia, universo, galaxias	música, cine, comercio	Astronomía ↔ Cultura / Comercio

8.2. Ejemplo 2: documentos cercanos

Para cada categoría tomamos un documento base y revisamos sus cinco vecinos más cercanos en el espacio reducido de rango $k = 20$. **Todos** los vecinos pertenecen a la misma categoría temática, con similitudes coseno robustas ($\geq 0,83$):

Tabla 3: Vecinos más cercanos en el espacio latente ($k = 20$) medidos por similitud coseno.

Documento base	Vecinos más cercanos (Similitud coseno)
Física (Ciencia)	Electromagnetismo (0.92), Mecánica cuántica (0.91), Termodinámica (0.90)
Cine (Cultura)	Historia del cine (0.96), Festival de Cannes (0.80), Premios Óscar (0.80)
Real Madrid CF (Deporte)	FC Barcelona (0.98), Premier League (0.96), UEFA (0.91), Camp Nou (0.86)
Economía (Economía)	PIB (0.95), Desigualdad de ingreso (0.90), Microeconomía (0.88)
Segunda Guerra Mundial	Primera Guerra Mundial (0.97), Guerra de Corea (0.95), Guerra de Vietnam (0.95)

LSA efectivamente construye un espacio métrico donde la **similitud geométrica equivale a similitud semántica**.

8.3. Ejemplo 3: términos cercanos a una palabra de consulta

Las consultas devuelven campos semánticos coherentes sin necesidad de un diccionario estructurado externo ni lematización pesada:

- gravedad $\rightarrow$ agujeros, negros, gravitatoria, curvatura, dimensiones (Relatividad/Cosmología).
- guerra $\rightarrow$ conferencia, conflicto, militar, aliados, derrota, contienda (Campo militar).
- inflación $\rightarrow$ monetarias, tasa, recesión, crédito, fiscal, dinero (Macroeconomía).
- película $\rightarrow$ óscar, festival, cannes, cineasta, guionista, documental (Cine).
- fútbol $\rightarrow$ fifa, iffhs, clubes, uefa, league, temporada (Instituciones futbolísticas).

8.4. Similitud entre categorías

La diagonal del heatmap muestra que la cohesión interna de cada categoría es de **3 a 5 veces mayor** que la similitud cruzada:

- **historia** se consolida como la más cohesiva internamente (0.524).
- **economía** (0.452) y **ciencia** (0.394) exhiben agrupaciones compactas.
- **deporte** (0.381) y **cultura** (0.358) reflejan menor cohesión debido a la diversidad interna del área (cultura abarca desde pintura y literatura hasta música y cine).

Fuera de la diagonal, el par cruzado más alto se da entre **historia y economía (0.210)**, lo cual **confirma la hipótesis 4**. Los pares más disjuntos son deporte–economía (0.100) y deporte–ciencia (0.100), consistente con nuestras intuiciones.




Figura 5: Matriz de confusión de similitud coseno promedio entre las cinco categorías.

9. Discusión, limitaciones y conclusiones

9.1. Comparación con la hipótesis inicial

Tabla 4: Matriz de contrastación de hipótesis iniciales.

#	Hipótesis Planteada	Resultado	Evidencia Clave
1	Clusters por categoría en plano 2D	Confirmado	Se logra con nitidez al evaluar (C2, C3).
2	Términos temáticos segregados	Confirmado	Los polos de $U_{:,k}$ ($k \geq 2$) son interpretables.
3	Concentración de energía en 5–10 σ_k	Refutado	Rango efectivo alto: $k = 20$ retiene solo 21 %.
4	Solapamiento entre historia y economía	Confirmado	Par cruzado más alto en el heatmap (0.210).

9.2. Resultados inesperados

- **La componente 1 no es temática:** Captura el sesgo de magnitud del vector TF-IDF (longitud y palabras comunes del artículo). Es un comportamiento característico de LSA documentado en la literatura, sugiriendo omitir C1 en tareas posteriores de clustering.
- **Excelente resolución con baja energía:** Con apenas el 21 % de la varianza explicada, las vecindades reducidas muestran una precisión asombrosa. Esto demuestra que la varianza matemática global y el poder de separación semántica operan en dimensiones prácticas distintas.

9.3. Limitaciones del modelo

- **Bolsa de palabras (Bag-of-Words):** El modelo descarta sintaxis y orden, haciendo que frases opuestas compartan vectores casi análogos.
- **Polisemia y ambigüedad:** Vocablos con múltiples acepciones (ej. *banco*) se colapsan en un único vector intermedio, distorsionando el espacio.
- **Escalabilidad:** La composición SVD densa completa mediante `numpy.linalg.svd` se vuelve prohibitiva computacionalmente con millones de datos, exigiendo el uso de solvers iterativos truncados como `scipy.sparse.linalg.svds`.

9.4. Conclusión

LSA respaldado por SVD demostró ser una potente herramienta no supervisada para la extracción y exploración automática de estructuras conceptuales latentes en textos complejos de Wikipedia. El álgebra lineal captura vecindades coherentes y agrupa el vocabulario de forma geométrica natural. La refutación de la hipótesis energética se tradujo en una lección teórica valiosa: no se requiere una reconstrucción matricial exacta de baja pérdida para extraer semántica útil del lenguaje humano.

Reproducibilidad

- **Repositorio:** Estructura de código limpia y modular adjunta en el directorio.
- **Datos:** Respaldados localmente en `corpus_wikipedia.csv` (294 filas) para aislar la dependencia de red.
- **Entorno de ejecución:** Desarrollado y verificado en entornos de Python 3.13 con librerías estándar actualizadas (`numpy`, `pandas`, `scikit-learn`, `matplotlib`, `seaborn`). Las rutas para regenerar figuras automáticas se encuentran parametrizadas de forma relativa.